

Estadística Descriptiva: Fundamentos y Métodos

Introducción a la estadística descriptiva

La estadística descriptiva es la rama de la estadística dedicada a recopilar, organizar, resumir y presentar datos de manera informativa. A diferencia de la estadística inferencial, que busca generalizar conclusiones a toda una población a partir de una muestra, la estadística descriptiva se limita a describir el conjunto de datos observado. Sus herramientas permiten transformar grandes volúmenes de información en medidas concretas y visualizaciones comprensibles.

Vivimos en una era de datos masivos: sensores, redes sociales, sistemas de salud y transacciones financieras generan miles de millones de registros cada día. Sin las herramientas de la estadística descriptiva, esa información sería ininteligible. Gracias a ella podemos resumir en pocas cifras las características esenciales de un conjunto de datos y comunicar hallazgos de forma clara y objetiva.

Medidas de tendencia central

Las medidas de tendencia central buscan identificar un valor representativo alrededor del cual se agrupan los datos. Las tres más comunes son la media aritmética, la mediana y la moda. La media es el promedio: se obtiene sumando todos los valores y dividiendo entre el número de observaciones. Es muy sensible a los valores extremos (outliers), lo que puede distorsionar su interpretación en distribuciones asimétricas.

La mediana es el valor que ocupa la posición central cuando los datos están ordenados de menor a mayor. Si el número de observaciones es par, se toma el promedio de los dos valores centrales. La mediana es robusta frente a los valores extremos y resulta más representativa que la media en distribuciones con colas largas, como los ingresos económicos. La moda, por su parte, es el valor que aparece con mayor frecuencia y puede existir más de una (distribuciones bimodales o multimodales).

Medidas de dispersión

Conocer el valor central de un conjunto de datos no es suficiente: también es fundamental saber qué tan dispersos están los datos alrededor de ese centro. Las principales medidas de dispersión son el rango, la varianza, la desviación estándar y el coeficiente de variación. El rango es la diferencia entre el valor máximo y el mínimo; es simple de calcular pero muy sensible a valores extremos.

La varianza mide el promedio de los cuadrados de las diferencias entre cada observación y la media. Su raíz cuadrada, la desviación estándar, tiene la ventaja de estar expresada en las mismas unidades que los datos originales, lo que facilita su interpretación. El coeficiente de variación —razón entre la desviación estándar y la media, multiplicada por 100— es especialmente útil para comparar la dispersión relativa de conjuntos de datos con diferentes unidades o magnitudes.

Distribuciones de frecuencia y visualización

Una tabla de frecuencias organiza los datos en clases o intervalos y muestra cuántas observaciones caen en cada uno. A partir de esta tabla se construyen histogramas, que son representaciones gráficas de la distribución de los datos. La forma del histograma revela características importantes: si es simétrico, si tiene una o varias colas pronunciadas, si existe multimodalidad, etc.

Otras representaciones visuales habituales en estadística descriptiva son el diagrama de caja (boxplot), que resume en un solo gráfico la mediana, los cuartiles y los valores atípicos; el diagrama de dispersión, para explorar relaciones entre dos variables; y el gráfico de sectores, adecuado para mostrar proporciones de categorías en una variable cualitativa. La elección del gráfico adecuado depende del tipo de variable y del mensaje que se desea comunicar.

Correlación y covarianza

Cuando se trabaja con dos variables numéricas, interesa saber si existe una relación lineal entre ellas. La covarianza mide en qué dirección varían conjuntamente dos variables: si es positiva, tienden a crecer juntas; si es negativa, cuando una crece la otra decrece. Sin embargo, la covarianza depende de las unidades de medida, lo que dificulta la comparación entre pares de variables.

El coeficiente de correlación de Pearson soluciona este problema al estandarizar la covarianza. Su valor oscila entre -1 y 1: un valor cercano a 1 indica correlación lineal positiva fuerte, cercano a -1 indica correlación negativa fuerte, y cercano a 0 sugiere ausencia de relación lineal. Es importante recordar que correlación no implica causalidad: dos variables pueden estar correlacionadas por la influencia de una tercera variable o simplemente por coincidencia.